

Qualidade em um processo de mineração

Análise exploratória de dados

Igor Peixoto Rodrigues

Estagiário - Ciência de Dados

igor@aignosi.com.br

30 de outubro de 2024

Disclaimer

Este relatório é parte integrante de um processo seletivo interno e tem como objetivo exclusivo fins didáticos. As análises aqui apresentadas não refletem a posição oficial da Aignosi e não geram qualquer tipo de vínculo empregatício ou compromisso por parte da empresa.

Copyright

© [2024] [Aignosi]

Contato

Rua Patagonia, 300.
Belo Horizonte, MG.
sales@aignosi.com.br
+55 31 9 9262-0163

Changelog

v1.0	30-10-2024	Dados iniciais. Panorama geral dos dados.
------	------------	---

Sumário

1 O processo de mineração e processamento: uma visão geral.....	4
2 Objetivos.....	6
3 Análise exploratória de dados	6
4 Resultados e Discussão	8
5 Conclusão e perspectivas	17
Referências.....	19



Figura 2: Mina de exploração e transporte de minério de ferro. Imagem retirada de [4]

Após a extração, o minério é transportado por caminhões até correias transportadoras ou ferrovias que o levam às usinas de beneficiamento. No beneficiamento, o minério passa por britagem, onde é quebrado em pedaços menores e separado de impurezas por processos como flotação, separação magnética e filtragem, aumentando assim o teor de ferro.

A escolha do método de beneficiamento mineral mais adequado varia de acordo com a composição específica do minério e as características das impurezas presentes. Técnicas como flotação por espuma, torrefação e fundição em alto-forno são comumente empregadas. A flotação, em particular, destaca-se como o método mais eficaz para a separação de impurezas do minério de ferro, devido à sua capacidade de selecionar partículas minerais com base em suas propriedades superficiais.




Figura 3: Célula de flotação de minério de ferro.

No processo de flotação (Figura 3), o minério de ferro finamente moído é misturado com água e outros reagentes químicos, como amido e aminas, para separar o mineral de ferro das suas impurezas. Nesse processo, as aminas atuam como coletores e agentes de espumação, ligando-se à superfície dos minerais de ferro para torná-los hidrofóbicos (que repelem água) e mais responsivos à flotação. Quando o ar forçado é borbulhado através da mistura líquida, o concentrado de ferro purificado será anexado às bolhas de ar e subirá para a superfície superior da planta de flotação como espuma. Todas as outras impurezas tornam-se hidrofílicas (que atraem água) e afundam no fundo da planta, e o excesso de água e minerais de resíduos serão descarregados através dos rejeitos. Se os rejeitos de minério de ferro não forem tratados adequadamente, eles causarão muitos perigos, incluindo poluição ambiental.

Pra garantir eficiência, viabilidade econômica e reduzir impactos ambientais, a análise de qualidade no processo de mineração é crucial. O processo começa com a amostragem, em que se coletam amostras representativas do minério em diferentes etapas. Essas amostras passam por análises químicas que identificam a composição do minério, incluindo impurezas como sílica, fósforo e enxofre, que podem afetar o beneficiamento. A avaliação do teor de minério é fundamental, pois garante que o minério extraído tenha uma concentração adequada do elemento desejado, como o ferro, que deve ter teor acima de 60% para ser economicamente viável. Minérios de baixa qualidade exigem beneficiamento adicional, aumentando custos.

2 Objetivos

Como objetivo principal busca-se realizar uma análise de um conjunto de dados reais provenientes de uma planta de flotação de minério de ferro. Através de técnicas de exploração e visualização de dados, pretende-se obter um entendimento de eventos típicos e atípicos do processo de produção. Com base nos resultados dessa análise, espera-se gerar insights valiosos e baseados em dados sobre a qualidade do concentrado de minério de ferro obtido ao final do processo de flotação, contribuindo para a otimização dos processos e a melhoria da qualidade do produto final.

3 Análise exploratória de dados

Os dados utilizados representam um conjunto de dados reais coletados de março de 2017 a setembro de 2017 de uma planta de flotação de minério de ferro. O dicionário de dados fornecido lista o nome da coluna, o tipo de dado e a descrição de cada coluna no conjunto de dados. Cada linha é um ponto no tempo a intervalos de 20 segundos. A coluna de data possui o dia, o mês, o ano e a hora, mas não mostra os minutos nem os segundos. Há 24 colunas. A fonte

do conjunto de dados é Kaggle [5]. Informações adicionais sobre o conjunto de dados podem ser encontradas aqui [6].

Tabela 1: Este conjunto de dados é sobre testes de flotação em uma planta de mineração, onde o objetivo é separar o minério de ferro em sua forma “pura” (Concentrado de Ferro) e sua “impureza” (Concentrado de Sílica) usando produtos químicos como amido e amina para completar este processo.

Nome de coluna	Tipo de dado	Descrição
Date	datetime64	Data e hora
% Iron Feed	float64	% de Ferro que vem do minério de ferro que está sendo alimentado nas células de flotação
% Silica Feed	float64	% de sílica (impureza) que vem do minério de ferro; isso impacta a ligação à floculação.
Starch Flow	float64	Fluxo de amido (reagente) medido em m^3/h ; este é um produto químico usado na operação de flotação
Amina Flow	float64	Fluxo de amina (reagente) medido em m^3/h ; outro produto químico usado na operação de flotação
Ore Pulp Flow	float64	Mistura de água, reagentes e ferro.
Ore Pulp pH	float64	Escala de pH de 0 a 14; parâmetro associado as reações químicas.
Ore Pulp Density	float64	Densidade do subfluxo do espessador; escala de densidade de 1 a 3 kg/cm^3 .
Flotation Column 01 - 07 Air Flow	float64	Estas 7 colunas mostram o fluxo de ar que entra na célula de flotação medido em Nm^3/h ; este é o ar necessário para a flotação onde o ar se transforma em bolhas na polpa e a quantidade de ar mostra o aumento da área de superfície dessas bolhas.
Flotation Column 01 - 07 Level	float64	Estas 7 colunas mostram o nível de espuma em milímetros acima da coluna medido em mm (milímetros); isso nos dá a espessura dos níveis de espuma - quanto maior o nível de espuma, menor a concentração flutua na concentração.

Nome de coluna	Tipo de dado	Descrição
% Iron Concentrate	float64	O produto do processo de flotação: % de Ferro representa quanto ferro está presente no final do processo de flotação (0-100%, medição de laboratório).
% Silica Concentrate	float64	O produto do processo de flotação: % de sílica (impureza) representa quanto ferro está contaminado com sílica no final do processo de flotação (0-100%, medição de laboratório).

Este conjunto de dados contém mais de 730.000 amostras ou alterações no processo de flotação. As colunas que medem o teor de ferro e o teor de sílica na alimentação são indicadores da qualidade do minério de ferro antes de sua entrada na planta de flotação. As variáveis mais críticas que influenciam a qualidade do minério no final do processo são o fluxo de amido, o fluxo de Amina, o fluxo de polpa de minério, o pH da polpa de minério e a densidade da polpa de minério. Além disso, o fluxo de ar e o nível de espuma de suspensão também afetam a qualidade do minério. Por fim, o teor de ferro concentrado e o teor de sílica concentrado são medidos novamente ao final do processo de flotação.

Os dados foram baixados como um arquivo de Valores Separados por Vírgulas (CSV) e depois importados para o Python, uma linguagem de programação de computador usada para realizar análise de dados. A análise dos dados foi conduzida utilizando um conjunto de bibliotecas Python altamente eficazes. O Pandas foi empregado para manipulação e limpeza dos dados, o Seaborn e o Matplotlib para visualização, e o NumPy para operações numéricas e matriciais.

4 Resultados e Discussão

O conjunto de dados fornecidos consistem em uma série temporal, isto é, um conjunto de observações coletadas ou registradas em intervalos de tempo sequenciais. Como informado na seção 3, são apresentadas além da informação temporal, vinte e três características do processo de beneficiamento por flotação. Afim de compreender o papel das variáveis críticas (o fluxo de amido, o fluxo de amina, o fluxo de polpa de minério, o pH da polpa de minério e a densidade da polpa de minério) e as variáveis secundárias (o fluxo de ar e o nível de espuma de suspensão) no processo de remoção da sílica, é interessante verificar inicialmente o comportamento associado a quanta sílica está presente inicialmente nas amostras e ao final do processo de beneficiamento. A figura 4 mostra a distribuição ao longo do tempo da concentração de sílica média diária.




Figura 4: Distribuição temporal da concentração de sílica média diária antes e após o beneficiamento..




Figura 5: Histograma da concentração de sílica após o processo de flotação.

Para facilitar a análise da série temporal, a construção do histograma permite analisar com maior eficiência os dados apresentados. Analisando a figura 5 notamos que a concentração de sílica após o processo de beneficiamento gira em torno de menos 3%. Isso indica que o processo de flotação é eficaz.

O mesmo procedimento foi realizado para o concentrado de ferro, como mostrado nas figuras 6 e 7. A análise visual e quantitativa mostra que a qualidade do minério após o beneficiamento encontra-se acima do valor recomendado que é

de 60%. Corroborando dessa maneira, com a confiabilidade do beneficiamento por flotação.




Figura 6: Distribuição temporal da concentração de ferro média diária antes e após o beneficiamento.




Figura 7: Histograma da concentração de ferro após o processo de flotação.

Na perspectiva de tornar ainda mais eficiente o processo de retirada de impurezas do minério de ferro, baseado nas informações disponíveis, algumas hipóteses pertinentes podem ser levantadas:

1. Quais das variáveis críticas, ao serem melhor controladas, podem impactar diretamente no processo de retira de sílica?

2. Quais das variáveis secundárias contribuem para o processo?

3. Todos os parâmetros influenciam o processo de beneficiamento?

Para buscar respostas para as hipóteses, em uma primeira análise, a geração de um mapa correlação entre as variáveis pode trazer informações relevantes. A correlação é uma medida de quanto uma grandeza possui dependência com uma outra. Comumente os valores estão dentro um intervalo $[-1,1]$ em que quanto mais próximo de 1 temos uma alta correlação proporcional, e quanto mais próximo de -1 temos uma alta correlação inversamente proporcional. O valor 0 significa a ausência de correlação. A figura 8 mostra essas relações de correlação para o conjunto de dados analisados.

Observando o mapa de correlação, nota-se que a correlação entre a concentração inicial e final de ferro e sílica apresentam valores negativos próximos de -1, valor no qual era esperado, uma vez que se temos muita concentração de minério de ferro esperamos ter uma baixa concentração de sílica. Quanto as valores positivos associados as colunas de fluxo de ar e do nível de espuma, os valores também são esperados, pois indicam que um aumento no fluxo de ar está associado a um aumento no nível de espuma. Este comportamento é consistente com a teoria de que o fluxo de ar auxilia na formação de espuma, o que é crucial para o processo de separação de minerais.

Fica evidente pela análise do mapa de correlação que existem muitas variáveis para serem tratadas ao mesmo tempo. Uma técnica eficiente para reduzir a dimensionalidade de um problema é a chamada PCA (*Principal Component Analysis - PCA*) [7, 8], que consiste em transformar um conjunto de variáveis possivelmente correlacionadas em um conjunto de valores de variáveis linearmente não correlacionadas, chamadas de componentes principais. A PCA busca identificar as direções (componentes principais) que capturam a maior variação nos dados, permitindo uma representação mais compacta e informativa do conjunto de dados original. A aplicação da PCA neste contexto pode ajudar a simplificar a análise, destacando as variáveis mais influentes e reduzindo o ruído causado por variáveis menos relevantes. Isso facilita a interpretação dos dados e pode revelar padrões ocultos que não seriam facilmente identificáveis em um espaço de alta dimensionalidade.

Cada componente principal é uma combinação linear das variáveis originais, ou seja, cada componente é formado por uma soma ponderada das variáveis iniciais. Os pesos aplicados a cada variável na composição dos componentes principais são denominados “loadings” (ou “carregamentos”) e indicam a contribuição relativa de cada variável para o componente, com o objetivo de maximizar a variância capturada. Esse processo de ponderação visa concentrar o máximo de informações dos dados originais, preservando características essenciais e relevantes para a análise. O primeiro componente principal (PC1) é determinado como a direção nos dados que captura a maior variância possível, representando a orientação com a maior dispersão e, portanto, a que concentra o maior volume




Figura 8: Mapa de correlação entre as variáveis. Valores positivos (azul) indicam correlação proporcional e valores negativos (vermelho) indicam correlação inversamente proporcional.

de informações. O segundo componente principal (PC2), por sua vez, é calculado em uma direção ortogonal (ou perpendicular) ao PC1 e captura a maior variância residual, ou seja, a variância não explicada pelo primeiro componente. Esse procedimento se repete para cada componente subsequente, respeitando sempre a ortogonalidade e garantindo que cada componente capture a máxima variância restante.

A figura 9 mostra a contribuição de cada componente principal, levando em consideração todos as características dos dados. Nota-se que a variância explicada diminui à medida que mais componentes são analisados, sugerindo que as primeiras componentes capturam a maior parte da informação dos dados.



Figura 9: Variância explicada para cada componente principal analisada.

Para verificar com maior eficiência qual o número de componentes que contribuem com a maior parte da informação, o uso da variância acumulada, que consiste na soma cumulativa das variâncias explicadas por cada componente principal, é essencial. A variância acumulada permite identificar quantos componentes principais são necessários para explicar uma certa porcentagem da variância total nos dados, facilitando a escolha do número adequado de componentes para análise. Cerca de 90% de toda a informação é capturada utilizando 10 componentes principais (Figura 10).




Figura 10: Variância explicada acumulada.

Para interpretar e descrever os resultados dos “loadings” dos componentes

principais em uma PCA, é útil seguir um processo organizado. Primeiramente, os “loadings” representam a correlação entre as variáveis originais e os componentes principais, indicando a contribuição de cada variável na formação desses componentes. Quanto maior o valor absoluto de um “loadings”, maior é a participação da variável associada naquele componente específico. A próxima etapa é identificar os maiores “loadings” em módulo para cada componente principal. As variáveis que exibem esses valores mais elevados são as que mais influenciam o componente e, portanto, ajudam a caracterizar a essência de cada um. Dessa forma, podemos compreender quais variáveis têm maior impacto nas direções de maior variância nos dados. A figura 11 captura a contribuição de cada característica do conjunto de dados em cada PCA.




Figura 11: Contribuição das variável para cada componente principal.

Tomando em módulo e escolhendo os 5 maiores valores de cada componente principal possibilitou a construção da tabela 2. Nota-se que a porcentagem inicial de concentrado de ferro e sílica tem grande contribuição para a maior parte das informações contidas nos dados. Esse resultado é esperado pois todo o restante do processo de beneficiamento depende dos valores iniciais dessas grandezas, pois influenciam diretamente a eficiência e o resultado do processo. Uma segunda observação é que dentro dos parâmetros críticos o pH da polpa, o

Tabela 2: **Tabela de Loadings.** Os “loadings” indicam a contribuição de cada variável original para a formação dos componentes principais, com valores maiores em módulo representando uma maior influência.

PC1	Flotation Column 06 Air Flow	Flotation Column 07 Air Flow	Flotation Column 01 Air Flow	Flotation Column 03 Air Flow	Flotation Column 01 Level
PC2	Flotation Column 05 Level	Flotation Column 04 Level	Flotation Column 07 Level	Flotation Column 06 Level	% Silica Concentrate
PC3	% Iron Feed	% Silica Feed	Ore Pulp Flow	% Iron Concentrate	Starch Flow
PC4	Ore Pulp Density	% Iron Feed	% Silica Feed	Amina Flow	Starch Flow
PC5	% Iron Concentrate	% Silica Concentrate	% Silica Feed	% Iron Feed	Flotation Column 04 Level
PC6	Ore Pulp Density	Flotation Column 02 Level	Flotation Column 01 Level	Flotation Column 03 Level	Amina Flow
PC7	Pulp pH	Flotation Column 05 Air Flow	Flotation Column 04 Air Flow	Flotation Column 02 Air Flow	Starch Flow
PC8	Ore Pulp Flow	Ore Pulp pH	Ore Pulp Density	Flotation Column 05 Air Flow	% Silica Concentrate
PC9	Flotation Column 05 Air Flow	Starch Flow	Ore Pulp Flow	Amina Flow	Ore Pulp pH
PC10	Ore Pulp pH	Flotation Column 06 Air Flow	Flotation Column 07 Air Flow	Starch Flow	Ore Pulp Flow

fluxo de amido e amina e a densidade do polpa contribuem com alto grau para a informação contida nos dados. E por fim, o fluxo de ar e o nível da espuma nas colunas de flotação superiores (5, 6 e 7) se mostram serem importantes, trazendo contribuições significativas para a variância explicada.

Partindo das informações contidas no parágrafo anterior, foi construído a série temporal para as variáveis críticas em conjunto com a série temporal para o concentrado final de sílica (Figura 12). Analisando as séries, observa-se os seguintes comportamentos:




Figura 12: Em verde serie temporal associada ao fluxo de amido, em azul o fluxo de amina, em lilás a pH da polpa e em ciano a densidade da polpa. Por último a série temporal para a concentração de sílica final.

1. Um baixo fluxo de amido ($< 3000m^3/h$), combinado com pH médio < 9.5 e densidade média da polpa $> 1.70kg/cm^3$ induzem a concentrações de sílica maiores.
2. Um fluxo de amido médio $> 3000m^3/h$ combinado com fluxo médio de amina $> 500m^3/h$, pH médio ≈ 10 e densidade da polpa entre $1,65 < x \leq 1.70kg/cm^3$ contribuem para concentrações de sílica $< 3\%$.
3. O pH pode impactar significativamente no quantidade de concentrado de sílica, visto que para valores próximos de 9, houve um aumento expressivo na quantidade.

Analisando as séries temporais para o fluxo de ar e o nível de espuma nas colunas finais (5, 6 e 7) em conjunto com a série temporal para o concentrado final de sílica (Figuras 13 e 14) , é possível inferir os seguintes comportamentos:

1. A espessura ou nível da espuma de flotação próximos de 400 mm, induzem no aumento do concentrado de sílica
2. O redução do fluxo de ar nas colunas de flotação finais, pra valores menores que $275 Nm^3/h$ podem contribuir para o aumento do nível de concentrado de sílica.

Essas observações destacam a importância de controlar precisamente as variáveis operacionais como o fluxo de amido, pH e densidade da polpa, bem como




Figura 13: Em ordem crescente (cima para baixo) as séries temporais do fluxo de ar nas colunas 5, 6 e 7 de flotação. Por último a série temporal para a concentração de sílica final.




Figura 14: Em ordem crescente (cima para baixo) as séries temporais da espessura da espuma nas colunas 5, 6 e 7 de flotação. Por último a série temporal para a concentração de sílica final.

o nível de espuma e fluxo de ar nas colunas de flotação. Ao otimizar essas condições, é possível melhorar significativamente a eficiência do processo de flotação, reduzindo a concentração de sílica no concentrado final e, conseqüentemente, aprimorando a qualidade do produto. Por fim, os resultados obtidos neste estudo revelam a complexidade intrínseca das relações entre as variáveis do processo de flotação e a concentração final de sílica. Embora tenhamos identificado algumas tendências significativas, a natureza multifatorial do sistema demanda uma abordagem mais robusta para desvendar os mecanismos subjacentes e estabelecer modelos preditivos precisos. O emprego de técnicas avançadas de machine learning e ciência de dados, como redes neurais artificiais e algoritmos de aprendizado de máquina, pode ser crucial para capturar as não-linearidades e interações complexas entre as variáveis, permitindo a construção de modelos preditivos mais robustos e acurados.

5 Conclusão e perspectivas

A análise exploratória de dados mostrou-se promissora ao revelar informações interessantes sobre a qualidade do minério de ferro após o processo de flotação. Identificou-se que a redução do pH da polpa de minério, combinada com a diminuição nas dosagens de amido e amina, está associada ao aumento da

concentração de sílica. Além disso, foi constatado que um controle mais preciso do fluxo de ar nas colunas finais do processo contribui para a redução dessa concentração de sílica.

Para os próximos passos, propõe-se o desenvolvimento de um sistema de otimização autônoma da produção, utilizando técnicas de *machine learning* para prever os valores ideais dos parâmetros críticos e secundários. Espera-se que impactos significativos sejam alcançados com essa abordagem. Primeiramente, a otimização dos processos permitirá reduzir os custos operacionais ao eliminar desperdícios e aumentar a eficiência no uso de insumos essenciais. Em segundo lugar, a implementação de modelos preditivos para monitorar e antecipar variações dos fatores-chave possibilitará decisões mais assertivas e respostas ágeis às mudanças operacionais, reduzindo paradas inesperadas e garantindo uma maior estabilidade na produção. Em terceiro, o controle rigoroso da qualidade, fundamentado em *insights* quantitativos, assegurará que o minério final atenda aos padrões de mercado, fortalecendo a reputação da empresa como fornecedor confiável e competitivo. Finalmente, ao adotar a ciência de dados, a empresa posiciona-se como líder em inovação no setor de mineração, diferenciando-se da concorrência e consolidando sua posição no mercado.

Assim, a aplicação contínua de técnicas de ciência de dados não apenas otimiza a qualidade e eficiência dos processos, mas também maximiza o lucro e aumenta a competitividade da empresa. Dessa forma, a ciência de dados se estabelece não apenas como uma oportunidade estratégica, mas como uma vantagem competitiva indispensável para o futuro do negócio.

Referências

- [1] UOL Educação. “Minério de Ferro: Brasil é um dos principais produtores mundiais”. Em: (2024). Acessado em: 11 de outubro de 2024. URL: <https://educacao.uol.com.br/disciplinas/geografia/minerio-de-ferro-brasil-e-um-dos-principais-produtores-mundiais.htm>.
- [2] Exame Invest. “Minério de Ferro: Qual a sua importância para a economia?”. Em: (2024). Acessado em: 11 de outubro de 2024. URL: <https://exame.com/invest/guia/minerio-de-ferro-qual-a-sua-importancia-para-a-economia/>.
- [3] Agência Nacional de Mineração. *Anuário Mineral Brasileiro: Principais Substâncias Metálicas*. Ed. por Marina Dalla Costa. il. Brasília: ANM, 2020, p. 30.
- [4] SunEnergy. *Industries Resources*. Accessed: 2024-10-11. 2024. URL: <https://suneng.com.au/industries/resources/>.
- [5] Edu Magalhaes. *Quality Prediction in a Mining Process*. Accessed: 2024-10-12. 2024. URL: <https://www.kaggle.com/datasets/edumagalhaes/quality-prediction-in-a-mining-process>.
- [6] Edu Magalhaes. *Quality Prediction in a Mining Process*. Accessed: 2024-10-12. 2024. URL: <https://www.kaggle.com/datasets/edumagalhaes/quality-prediction-in-a-mining-process/discussion/182482>.
- [7] Lauro Vicari. *No Detalhe: Principal Component Analysis (PCA)*. Acessado em: 15 de outubro de 2024. 2023. URL: <https://medium.com/@laurovicari/no-detalhe-principal-component-analysis-pca-b26a3d03b028>.
- [8] Jake Lever, Martin Krzywinski e Naomi Altman. “Points of significance: Principal component analysis”. Em: *Nature methods* 14.7 (2017), pp. 641–643.